

Uwagi

2: KS: tytuł

Contents

1	Introduction	2
2	Rozmyty algorytm aglomeracyjnego grupowania hierarchicznego	2
2.1	Granulacja danych oryginalnych	3
2.2	Przekształcenie granul	3
2.3	Rozmyte grupowanie hierarchiczne	4
3	Badania	5
3.1	Zbiory danych	5
3.2	Metodyka badań	8
3.2.1	Czas grupowania	8
3.2.2	Jakość grupowania	10
3.3	Wyniki	17
3.3.1	Czas grupowania	17
3.3.2	Jakość grupowania	19
4	Podsumowanie	57

GrAgglo: A granular agglomerative clustering algorithm [tytuł]

1st October 2026

Abstract

Keywords: hierarchical clustering, fuzzy C-means, granular computing, fuzzy numbers, Python

1 Introduction

- Clustering algorithms
- High time complexity (hierarchical algorithm)
- Article sections

2 Rozmyty algorytm aglomeracyjnego grupowania hierarchicznego

Problemem algorytmów grupowania hierarchicznego jest ich duża złożoność czasowa – w przypadku algorytmu ogólnego aż do $O(X^3)$, gdzie X to liczba danych. Zmniejszenie liczby danych poprzez zastosowanie wstępnej granulacji algorytmem rozmytych c -średnich może znacznie przyspieszyć jego działanie, jako że algorytm ten ma stałą złożoność czasową w zależności od liczby danych ($O(X)$).

Zaproponowano rozmyty algorytm aglomeracyjnego grupowania hierarchicznego: GRAGGLO. Składa się on z trzech głównych kroków:

1. granulacja oryginalnych danych przy pomocy algorytmu rozmytych c -średnich (roz. 2.1),

2. przekształcenie otrzymanych wyników w granule o potrzebnych parametrach (roz. 2.2),
3. aglomeracyjne grupowanie hierarchiczne granul z uwzględnieniem ich rozmycia: FUZZYAGGLO (roz. 2.3).

Złożoność czasowa tego algorytmu może zostać określona jako $O(X + XG + G^3)$, przy czym $G \ll X$ odpowiada liczbie granul.

Implementacja algorytmu, skrypty pomocnicze pozwalające na analizę jego działania, badane dane syntetyczne oraz wyniki uzyskane na ich podstawie zamieszczono w repozytorium pod adresem <https://github.com/ZofiaLor/magister-granule>.

2.1 Granulacja danych oryginalnych

W pierwszym kroku oryginalne dane są granulowane przez algorytm rozmytych c -średnich. Dane mają postać macierzy liczb rzeczywistych o wymiarach $X \times D$, gdzie X – liczba danych, D – liczba atrybutów. Wartość parametru rozmycia m algorytmu określona jest na stałe jako 2. Liczba docelowych klastrów C jest jednym z parametrów badawczych i jest znacznie mniejsza od X .

Wyjściem tego kroku algorytmu będą struktury wyznaczone przez algorytm FCM, w szczególności wektor środków klastrów $\mathbf{v}$ oraz macierz przynależności danych do klastrów $\boldsymbol{\mu}$.

2.2 Przekształcenie granul

Granule wykorzystywane do grupowania hierarchicznego mają postać wielowymiarowych rozszerzalnych liczb rozmytych. Dla każdego wymiaru musi zostać określona wartość ostra liczby x oraz jej rozmycie p .

Wartości ostre są tożsame ze środkami klastrów będących wynikiem algorytmu rozmytych c -średnich, czyli z wektorem $\mathbf{v}$ (wzór ??).

Wartościom rozmycia nie odpowiada bezpośrednio żadna ze struktur zwracanych przez FCM. Dla każdego klastra c i wymiaru (atrybutu) d , rozmycie oblicza się jako następujące odchylenie standardowe:

$$p_{cd} = \sqrt{\frac{\sum_{i=1}^X \mu_{ci}^m (x_{id} - v_{cd})^2}{\sum_{i=1}^X \mu_{ci}^m}}. \quad (1)$$

Wyjściem tego kroku jest zbiór granul $\mathbb{G}$ – obiektów posiadających listę d -elementową liczb rozmytych, które z kolei zawierają informacje o wartościach

x i p . Granule nie mają na stałe określonego kształtu rozszerzalnych liczb rozmytych, które składają się na ich wymiary. Kształt jest więc parametrem dla operacji logicznych na nich wykonywanych. Złożoność czasowa tego kroku wynosi $O(XG)$

Liczby rozmyte stanowią rozszerzenie liczb ostrych, więc każda arytmetyczne i logiczna operacja rozmyta zwraca poprawny wynik również wtedy, gdy ich parametrami są liczby, dla których $p = 0$. Implementacja operacji $=_S$ w przypadku, gdy obydwie liczby są ostre, wykonuje zwykłą, ostrą operację logiczną $=$, w przeciwnym razie wystąpiłoby dzielenie przez 0. Operacja zwraca 1, jeżeli liczby są równe, 0, jeżeli nie są zamiast wartości logicznych odpowiednio prawda lub fałsz.

2.3 Rozmyte grupowanie hierarchiczne

Zbiór granul $\mathbb{G}$ oraz ich kształt są parametrami wejściowymi algorytmu rozmytego aglomeracyjnego grupowania hierarchicznego FUZZYAGGLO. Na początku wyznaczone są rozmyte odległości euklidesowe (wzór (??)) między każdą parą granul, przy pomocy operacji arytmetycznych określonych w sekcji ?? (alg. 4). Wynikiem obliczeń jest symetryczna macierz odległości $\mathbf{D}$ o wymiarach $X \times X$, gdzie $d_{ij} = d_{ji} = d(\mathbf{x}_i, \mathbf{x}_j)$. Odległość danego elementu od samego siebie (d_{ii}) nie jest wykorzystywana w algorytmie, jej wartość nie jest więc istotna.

Grupowanie hierarchiczne FUZZYAGGLO ma postać zmodyfikowanego algorytmu naiwnego PRIMITIVECLUSTERING, o złożoności czasowej $O(G^3)$. Zmieniony musi zostać sposób wyznaczania kolejnych minimalnych odległości w macierzy $\mathbf{D}$ oraz, zależne od łączności, aktualizacje odległości do nowo scalonego klastra.

Minimum i maksimum wyznacza się przy pomocy operacji porównania. W przypadku rozszerzalnych liczb rozmytych, wynikami takich operacji są liczby z przedziału $[0, 1]$. W celu określenia, która z liczb rozmytych jest większa lub mniejsza, wprowadzony zostaje parametr progowy ξ , będący parametrem badawczym. Algorytmy rozmytego minimum i maksimum przedstawiają odpowiednio pseudokody 1 i 2. Na podstawie alg. 1 można też utworzyć rozmytą funkcję $\arg \min$ (alg. 3).

Dla łączności SINGLELINKAGE, algorytm FUZZYAGGLO ma postać opisaną pseudokodem 5. Ten sam algorytm dla łączności COMPLETELINKAGE jest niemal identyczny: należy jedynie podmienić wywołanie algorytmu rozmytego minimum (alg. 1) w linii 10 na algorytm rozmytego maksimum (alg. 2).

Algorytm 1 Minimum rozmyte

Require: a, b : porównywane rozszerzalne liczby rozmyte

Require: r : typ relacji (trójkątna, wykładnicza, gaussowska)

Require: ξ : wartość progowa

```
1: procedure FUZZYMINIMUM( $a, b, r, \xi$ )
2:   if ( $a <_{S_r} b$ )  $> \xi$  then
3:     return  $a$ 
4:   else
5:     return  $b$ 
6:   end if
7: end procedure
```

Algorytm 2 Maksimum rozmyte

Require: a, b : porównywane rozszerzalne liczby rozmyte

Require: r : typ relacji (trójkątna, wykładnicza, gaussowska)

Require: ξ : wartość progowa

```
1: procedure FUZZYMAXIMUM( $a, b, r, \xi$ )
2:   if ( $a >_{S_r} b$ )  $> \xi$  then
3:     return  $a$ 
4:   else
5:     return  $b$ 
6:   end if
7: end procedure
```

3 Badania

Działanie algorytmu GRAGGLO musi zostać zbadane pod kątem czasu wykonania oraz jakości grupowania, również w porównaniu z jego ostrym odpowiednikiem.

3.1 Zbiory danych

Pierwszym zbiorem danych są dane syntetyczne, które znajdują się w plikach `.data` zlokalizowanych w folderze `dane`, pogrupowanych w podfoldery według kształtów. Dla każdego kształtu zbiory mają liczebność 1000, 2000, 5000, 10 000, 20 000, 30 000, 40 000 oraz 50 000 wierszy.

Dane mają postać współrzędnych punktów w dwóch lub trzech wymiarach – każdy wiersz w pliku reprezentuje współrzędne jednego punktu, współrzędne oddzielone są znakami tabulacji. Taka liczba wymiarów pozwala na wizualizację całości danych w postaci wykresu. W zależności od kształtu,

Algorytm 3 Rozmyta funkcja arg min

Require: $\mathbf{X}$: macierz liczb rozmytych, $\mathbf{p}$: wektor indeksów, dla których znajduje się minimum, r : typ relacji (trójkątna, wykładnicza, gaussowska), ξ : parametr porównania

```
1: procedure FUZZYARGMIN( $\mathbf{X}, r, \xi$ )
2:   result  $\leftarrow \infty_{S(0)}$   $\triangleright$  liczba rozmyta, dla której  $x = \infty, p = 0$ 
3:    $(w, k) \leftarrow (0, 0)$   $\triangleright$  Współrzędne (wiersz, kolumna) wartości
   minimalnej w przeszukiwanej części macierzy  $\mathbf{X}$ 
4:   for  $i = 1$  to  $|\mathbf{p}| - 1$  do
5:     for  $j = i + 1$  to  $|\mathbf{p}|$  do
6:        $p_w \leftarrow \mathbf{p}[i]$ 
7:        $p_k \leftarrow \mathbf{p}[j]$ 
8:       if  $(\mathbf{X}[p_w][p_k] <_{S_r} \text{result}) > \xi$  then
9:         result  $\leftarrow \mathbf{X}[p_w][p_k]$ 
10:         $(w, k) \leftarrow (p_w, p_k)$ 
11:       end if
12:     end for
13:   end for
14:   return  $(w, k)$   $\triangleright$  Współrzędne (wiersz, kolumna) wartości minimalnej
   w przeszukiwanej części macierzy  $\mathbf{X}$ 
15: end procedure
```

dla danego zbioru można na podstawie wykresu wyróżnić 2, 3 lub 4 wyraźnie odseparowane klastry. Wykresy danych przedstawiono na rys. 1, a w tabeli 1 – dodatkowo ich charakterystykę (liczbę wymiarów i klastrów).

Dane te nie posiadają etykiet. W sposób opisany w sekcji na stronie 11 każdemu punktowi przypisano etykietę w postaci liczby całkowitej $[0, C - 1]$ i zapisano w folderze `dane_labelled` w analogicznym formacie.

Wykorzystano również zbiory danych ‘brightkite’ [?] (4 491 143 wierszy) oraz ‘gowalla’ [?] (6 442 890 wierszy). Dane przedstawiają informacje o logowaniach się użytkowników platform społecznościowych. Dane przycięto, aby zawierały jedynie kolumny „latitude” oraz „longitude” – dwuwymiarowe współrzędne lokalizacji logowań. Dane nie są etykietowane i nie mają przypisanych klas. Analiza wykresów (rys. 2) pozwala zauważyć kształty kontynentów – można uznać je za docelowe klastry. Dane zawierają błędne współrzędne. W danych ‘brightkite’, kolumna „latitude” (szerokość geograficzna) zawiera wartości z przedziału $[-163.193\,333, 151.198]$, podczas gdy dopuszczalnym przedziałem jest $[-90, 90]$. Dla danych ‘gowalla’ przedział ten wynosi $[-90, 405.658\,498]$. Błędne współrzędne pozostawiono w zbiorze danych.




Figure 1: Wykresy danych o różnych kształtach z folderu **dane** o rozmiarze 1000 punktów.

Table 1: Charakterystyka zbiorów danych dołączonych do projektu.

	‘blobs’	‘circles’	‘corners’	‘crescents’	‘laguna’	‘spheres’
liczba klastrow	3	2	4	2	3	2
liczba wymiarów	2	2	2	2	2	3

Algorytm 4 Rozmyte odległości euklidesowe

Require: $\mathbf{X}$: macierz liczb rozmytych

```
1: procedure FUZZYDISTANCE( $\mathbf{X}$ )
2:   result  $\leftarrow \infty_{S(0)}$   $\triangleright$  liczba rozmyta, dla której  $x = \infty, p = 0$ 
3:    $X \leftarrow |\mathbb{X}|$   $\triangleright$  liczba danych
4:    $\mathbf{D} \leftarrow$  macierz zerowa  $X \times X$ 
5:   for  $i = 1$  to  $X - 1$  do
6:     for  $j = i + 1$  to  $X$  do
7:        $d_{ij} \leftarrow 0_0$   $\triangleright$  liczba rozmyta, dla której  $x = 0, p = 0$ 
8:       for  $k$  in  $|\mathbf{X}[i]|$  do  $\triangleright$  dla każdego wymiaru liczby rozmytej
9:          $d_{ij} \leftarrow d_{ij} + (\mathbf{X}[i][k] - \mathbf{X}[j][k])^2$   $\triangleright$  Operacje arytmetyczne
           na liczbach rozmytych (wzór (??))
10:      end for
11:       $d_{ij} \leftarrow \sqrt{d_{ij}}$   $\triangleright$  Operacja arytmetyczna na liczbie rozmytej
           (wzór (??))
12:       $\mathbf{D}[i][j] \leftarrow \mathbf{D}[j][i] \leftarrow d_{ij}$   $\triangleright$  macierz jest symetryczna względem
           przekątnej
13:    end for
14:  end for
15:  return  $\mathbf{D}$   $\triangleright$  macierz rozmytych odległości między parami liczb
           rozmytych
16: end procedure
```

3.2 Metodyka badań

Algorytm GRAGGLO (2) zbadano pod kątem szybkości wykonania oraz jakości grupowania poprzez porównanie jego efektów z efektami ostrego algorytmu aglomeracyjnego grupowania hierarchicznego SINGLELINKAGE i COMPLETELINKAGE.

3.2.1 Czas grupowania

Aby znaleźć charakterystykę zależności czasu wykonania algorytmów od liczby danych, przygotowano dane o rozmiarach 500-10 000 z krokiem 500. W tym celu brane były początkowe podzbiory ze zbiorów danych o rozmiarze 10 000. Jako że nieistotne były wyniki grupowania, nie było konieczne losowe próbkowanie.

Przyjęto też stałą maksymalną liczbę 80 iteracji algorytmu rozmytych c -średnich. Sekcja 3.3.2 pokazuje, że jest to wystarczająca wartość. Złożoność algorytmu jest liniowa w zależności od liczby iteracji [?]. Algorytm wykonano

Algorytm 5 Algorytm rozmytego aglomeracyjnego grupowania hierarchicznego FUZZYAGGLO (SINGLELINKAGE)

Require: $\mathbb{X}$: dane do klasteryzacji

Require: C : docelowa liczba klastrów

Require: r : typ relacji (trójkątna, wykładnicza, gaussowska)

Require: ξ : wartość progowa

```

1: procedure FUZZYAGGLO( $\mathbb{X}, C, r, \xi$ )
2:    $X \leftarrow |\mathbb{X}|$  ▷ liczba danych
3:    $\mathbf{D} \leftarrow \text{FUZZYDISTANCE}(\mathbb{X})$  ▷ symetryczna macierz  $X \times X$  rozmytych
   odległości euklidesowych między każdą parą danych
4:    $\mathbf{p} \leftarrow [1, 2, \dots, X - 1, X]$  ▷ wektor indeksów, które będą sprawdzane
5:    $\mathbf{e} \leftarrow [1, 2, \dots, X - 1, X]$  ▷ etykiety
6:   for  $i = 1$  to  $X - C$  do
7:      $w, k \leftarrow \text{FUZZYARGMIN}(\mathbf{D}, \mathbf{p}, r, \xi)$  ▷ znalezienie indeksów dwóch
     najbliższych klastrów
8:      $\mathbf{p} \leftarrow \mathbf{p} \setminus k$  ▷ nieużywane w dalszych iteracjach
9:     for  $p \in \mathbf{p}$  do
10:       $\mathbf{D}[w, p] = \mathbf{D}[p, w] = \text{FUZZYMINIMUM}(\mathbf{D}[w, p], \mathbf{D}[k, p], r, \xi)$  ▷
      przypisanie wynikające z łączności
11:    end for
12:     $\mathbf{e} \leftarrow \text{SCAL}(\mathbf{e}, w, k)$  ▷ zamiana wszystkich etykiet o wartości  $k$  na
    wartość  $w$ .
13:  end for
14:   $\mathbf{e} \leftarrow \text{PRZEMIANY}(\mathbf{e})$  ▷ przemianowanie etykiet  $\mathbf{e}$  na kolejne liczby
  od 0.
15:  return  $\mathbf{e}$ 
16: end procedure

```

też dla różnych licznosci granul: 50, 100 oraz 200.

Czas pojedynczego wykonania algorytmu ostrego zmierzono poprzez różnicę czasu rozpoczęcia i zakończenia grupowania hierarchicznego. Wykorzystany został algorytm `AgglomerativeClustering` biblioteki `scikit-learn` (łączność `SINGLELINKAGE`) oraz własna implementacja ostrego algorytmu grupowania, analogiczna do wersji rozmytej. Pozwoliło to na lepszy pogląd na wpływ granulacji na szybkość, jako że sama logika grupowania we własnej implementacji pozostała ta sama, co w algorytmie rozmytym. Algorytm biblioteczny ma z kolei najniższą złożoność czasową dla łączności `SINGLELINKAGE` (wykorzystuje algorytm minimalnego drzewa rozpinającego), można więc porównać czas wykonania `GRAGGLO` z najlepszym możliwym czasem grupowania tych samych danych algorytmem ostrym. Do tego porównania




Figure 2: Wykresy danych ‘brightkite’i ‘gowalla’.

wykorzystano oryginalne dane wejściowe, we wszystkich rozmiarach (1000-50 000). W czasie pojedynczego wykonania algorytmu rozmytego zawarto czas wykonania algorytmu rozmytych c -średnich, utworzenia na jego podstawie listy granul oraz rozmytego grupowania hierarchicznego.

Poszczególne pomiary czasu działania algorytmu dla dokładnie takich samych rozmiarów danych mogą różnić się o kilka milisekund. Wynika to między innymi z działania w tle innych procesów komputera, na którym przeprowadzane są badania. Typowym rozwiązaniem tego problemu jest kilkukrotne powtórzenie pomiarów dla tych samych danych i obliczenie średniej arytmetycznej wyników. Podczas badań pomiary powtórzono czterokrotnie, co wystarczyło do wyeliminowania odstających wyników.

Wykonano również pomiary czasu wykonania algorytmu GRAGGLO dla dużych liczebności danych: 50 000, 100 000, 500 000, 1 000 000, 2 000 000, 3 000 000, 4 000 000, 5 000 000 i 6 000 000, dla liczebności granul 50, 100 i 200. Jako że dla tak dużych rozmiarów danych czas ten jest rzędu minut, nie mają znaczenia milisekundowe przekłamania wyników. Z tego powodu wystarczyło wykonać jeden pomiar dla każdego rozmiaru danych.

3.2.2 Jakość grupowania

Jakość zmierzono poprzez porównanie wyników algorytmu GRAGGLO z oczekiwanymi przynależnościami punktów do klastrów, oznaczonymi etykietami. Jako miary jakości wykorzystano dokładność, trafność oraz precyzję.

Pomiary wykonano dla wszystkich kształtów i rozmiarów danych. W

przypadku algorytmu rozmytego, pomiary przeprowadzono również dla różnych łączności (SINGLELINKAGE, COMPLETELINKAGE), liczebności granul (50, 100, 200), typu relacji liczb rozmytych (trójkątne, wykładnicze, gaussowskie) oraz parametru $\xi \in \{0.05, 0.10, 0.15, \dots, 0.95\}$.

Podobnie jak w przypadku pomiarów czasu grupowania, przyjęto stałą maksymalną liczbę 80 iteracji. Sparаметryzowanie tej wartości oznaczałoby badanie działania bibliotecznej funkcji FCM, zamiast własnego algorytmu.

Kolejność danych została przed pomiarem losowo zmieszana przy pomocy generatora liczb pseudolosowych o ustalonym ziarnie. Dzięki temu, przy każdym uruchomieniu kolejność ta jest identyczna, wystarczyły więc jednokrotne pomiary wyników działania algorytmu GRAGGLO dla każdej kombinacji parametrów.

Etykietowanie danych W celu przypisania etykiet do danych z folderu `dane`, przygotowano pomocniczy skrypt w pliku `label_assignment.py`. W zależności od tego, czy dane są dwu- czy trójwymiarowe, przypisanie etykiet odbywa się na inny sposób.

Dane dwuwymiarowe Oznaczanie etykiet dla danych dwuwymiarowych wykorzystuje widżet `LassoSelector` biblioteki `matplotlib`. Dla każdego pliku z danymi dwuwymiarowymi, wyświetlono wykres połączony z obiektem klasy `SelectFromCollection` z przykładu [?]. Klasa ta między innymi umożliwia wyznaczenie indeksów i współrzędnych punktów zaznaczonych myszą na wykresie.

Każdemu punktowi domyślnie przypisano etykietę 0. Po zaznaczeniu zbioru punktów na wykresie naciśnięcie klawisza cyfry na klawiaturze powoduje przypisanie tym punktom etykiety o danym numerze i wyświetlenie w konsoli informacji, ilu punktom ją przypisano. Proces można powtarzać dowolną liczbę razy, można go zakończyć poprzez naciśnięcie klawisza ENTER i zamknięcie wykresu.

W celu ostatecznej weryfikacji pojawia się drugi wykres, na którym każdej etykietce odpowiada inny kolor. Po zamknięciu tego wykresu, plik z etykietami jest zapisywany w folderze `dane_labelled`. Plik ma format zgodny z oryginalnym plikiem z danymi (każdy wiersz to oddzielone znakami tabulacji współrzędne jednego punktu), z dodaną dodatkową kolumną z etykietami punktów.

Dane trójwymiarowe W przypadku danych trójwymiarowych skorzystano z faktu, że jedyne dane wykorzystywane w pracy, dla których należy znaleźć etykiety, to dane ‘spheres’. Punkty otrzymane z tych danych tworzą




Figure 3: Wykresy danych o różnych kształtach z folderu `dane_labelled` o rozmiarze 1000 punktów, o etykietach oznaczonych kolorami.

dwie sfery: mniejsza, wewnętrzna sfera jest zamknięta w sześcianie o wymiarach $1 \times 1 \times 1$ jednostek, a punkty drugiej, większej sfery znajdują się poza tym sześcianem. Wszystkim punktom, których wszystkie współrzędne mają wartości mniejsze lub równe 1 przypisano etykietę 1, pozostałym – 0. Dane z etykietami zostały zapisane w folderze `dane_labelled`, w takim samym formacie, jak dane dwuwymiarowe.

Wyniki etykietowania Na wykresie 3 przedstawiono wyniki etykietowania danych. Punkty oznaczone tym samym kolorem mają te same etykiety.

W przypadku danych ‘laguna’ o liczebności 20 000 i większej, dwa środkowe klastry przestają być wyraźnie oddzielone od siebie (rys. 4). Liczebności tych klastrów po podziale ich narzędziem `LassoSelector` nie są równe, jak w przypadku mniejszych zbiorów o tym samym kształcie – różnice wynoszą nie więcej niż 18 punktów. Przy tak dużych zbiorach danych wpływ pojedynczych punktów jest marginalny, należy jednak uwzględnić tę niepewność w analizie wyników jakości grupowania.




Figure 4: Wykres danych ‘laguna’ z folderu `dane_labelled` o rozmiarze 20 000 punktów, o etykietach oznaczonych kolorami.

Miara jakości Wybranymi miarami jakości grupowania są dokładność A , trafność R i precyzja P .

W przypadku dwuklasowym (klasy positive i negative), dokładność (ang. accuracy) jest definiowana jako:

$$A = \frac{TP + TN}{TP + FP + TN + FN}, \quad (2)$$

gdzie:

- TP – liczba danych poprawnie zaklasyfikowanych do klasy positive
- FP – liczba danych niepoprawnie zaklasyfikowanych do klasy positive
- TN – liczba danych poprawnie zaklasyfikowanych do klasy negative
- FN – liczba danych niepoprawnie zaklasyfikowanych do klasy negative

Dokładność jest łatwo rozszerzalna na więcej klas: sumę liczb danych poprawnie zaklasyfikowanych do każdej klasy należy podzielić przez liczbę wszystkich danych.

Trafność (czułość, ang. recall) definiowana jest jako:

$$R = \frac{TP}{TP + FN}, \quad (3)$$

czyli stosunek liczby danych poprawnie zaklasyfikowanych do klasy positive do wszystkich danych do niej należących.

Precyzję (ang. precision) definiuje się jako:

$$P = \frac{TP}{TP + FP}, \quad (4)$$

czyli stosunek liczby danych poprawnie zaklasyfikowanych do klasy positive do wszystkich danych które zostały do niej zaklasyfikowane.

Trafność i precyzję można rozszerzyć na wiele klas na różne sposoby. W badaniach wybrano metodę, w której najpierw obliczana jest wartość metryk cząstkowych dla każdej klasy z osobna (jedna klasa odpowiada klasie positive, wszystkie pozostałe – negative), a następnie obliczana jest z nich średnia arytmetyczna. Oznacza to, że każda klasa ma jednakową wagę dla ostatecznego wyniku – jeżeli będą miały różne licznosci, to klasy zawierające małą liczbę danych będą mieć proporcjonalnie większy wpływ na wyniki trafności i precyzji, niż dokładności.

Przynależność punktów do granul Rozmyty algorytm grupowania jako wynik zwraca przynależność do klastrów granul, nie oryginalnych danych. Na potrzeby porównania konieczne jest określenie, do której granuli należy każdy punkt. Przynależność tą wyznaczano na dwa sposoby na podstawie (1) macierzy przynależności do klastra wyznaczonego przez algorytm rozmytych c -średnich μ i (2) wartości relacji $*$ -podobieństwa S .

Pierwsze podejście dla każdego punktu i , znajduje granulę, dla której wartość odpowiedniego wiersza w macierzy przynależności μ_i jest maksymalna.

Drugie podejście przedstawia pseudokod 6. Dla każdego punktu i , przynależność do granuli j obliczana na podstawie wartości operacji $=_S$ (wzór ??) dla każdego wymiaru punktu i granuli. Operacja ta jest zależna od kształtu granul, dla liczb trójkątnych, wykładniczych i gaussowskich należy wykorzystać odpowiednio wzory ??, ?? lub ?? uwzględniając, że dla liczby ostrej (współrzędnej oryginalnego punktu) $p = 0$.

Wyniki dla każdej współrzędnej łączone są t -normą algebraiczną (wzór ??). Wreszcie określa się, że punkt należy do tej granuli, dla której wynik tego złączenia jest maksymalny.

Należy uwzględnić, że rozszerzalne liczby rozmyte trójkątne mają skończony nośnik. Oznacza to, że punkt może nie należeć do żadnej granuli – dla każdej z nich przynależność będzie zerowa. Punkt taki uznawany jest za szum i nie bierze udziału w wyznaczaniu wartości dokładności, trafności i precyzji, jednak odsetek punktów stanowiących szum jest w tym przypadku dodatkową miarą jakości.


Rysunek 5 przedstawia przykład takiego przypisania punktów do granul, dla czytelności wykresów wyznaczono jedynie 10 granul. Wykresy dla liczb wykładniczych i gaussowskich są bardzo podobne, ponadto wszystkie punkty są przypisane do granul. W przypadku liczb trójkątnych, duża część punktów stanowi szum.

Macierz pomyłek i obliczanie miar jakości Wyznaczono macierz $\mathbf{L}$, w której wartość elementu l_{ij} jest równa liczbie punktów, dla których oczekiwana etykieta ma wartość i i przynależących do klastra j wyznaczonego przez algorytm GRAGGLO:

$$l_{ij} = \sum_{k=0}^N [x_k \in i \wedge x_k \in j]. \quad (5)$$

Sposób wyznaczenia tej macierzy przedstawiono również na pseudokodzie 7.

Numeracja klastrów wyznaczonych przez algorytm GRAGGLO może być inna od oczekiwanych etykiet ze względu na różną kolejność ich wyznaczenia. Wykorzystując algorytm przedstawiony na pseudokodzie 8, wyznaczono taką



(a) Liczby trójkątne (b) Liczby wykładnicze (c) Liczby gaussowskie

Figure 5: Przynależność punktów do granul w zależności od kształtu liczb rozmitych. 10 środków granul oznaczono kolorem czerwonym, punkty należące do różnych granul oznaczone są różnymi kolorami. Kolorem szarym oznaczono punkty stanowiące szum.

permutację wierszy i kolumn macierzy $\mathbf{L}$, która maksymalizuje wartości na przekątnej.

Z uzyskanej w ten sposób macierzy pomyłek, dokładność wyznaczana jest jako suma wartości na przekątnej macierzy podzielona przez całkowitą liczbę danych:

$$A = \frac{\sum_{i=0}^C l_{ii}}{N} \quad (6)$$

lub

$$A = \frac{\sum_{i=0}^C l_{ii}}{\sum_{i=0}^C \sum_{j=0}^C l_{ij}}, \quad (7)$$

gdzie C to liczba klastrów.

Trafność (R) i precyzja (P) wyznaczane są najpierw osobno dla każdego klastra c :

$$R_c = \frac{l_{cc}}{\sum_{i=0}^C l_{ci}}, \quad (8)$$

$$P_c = \frac{l_{cc}}{\sum_{i=0}^C l_{ic}}. \quad (9)$$

Trafność i precyzja dla całości wyników otrzymywane są jako średnia arytmetyczna metryk częściowych:

$$R = \frac{\sum_{i=0}^C R_i}{C}, \quad (10)$$

$$P = \frac{\sum_{i=0}^C P_i}{C}. \quad (11)$$

Sposób obliczenia metryk jakości przedstawia również pseudokod 9.

Jeżeli dane zawierają szum, może on być interpretowany na dwa sposoby w kontekście wyznaczania metryk:

1. Szum nie jest brany pod uwagę, analizowane są jedynie dane niebędące szumem.
2. Szum uznawany jest za błędną klasyfikację. Aby skorygować wartość metryki o szum, należy pomnożyć ją przez odsetek punktów niebędących szumem w stosunku do całości danych. Na przykład, jeżeli początkowa wartość metryki wynosi 80%, a 40% danych stanowi szum, to ostateczna wartość tej metryki będzie równa $80\% * (100\% - 40\%) = 48\%$.

Oprócz niezależnych procentowych średnich wartości metryk dokładności, trafności i precyzji istotne jest, jakie są wyniki działania GRAGGLO w porównaniu z algorytmem ostrym. W tym celu wykorzystano algorytm `AgglomerativeClustering` biblioteki `scikit-learn` aby zgrupować dane oryginalne, a także środki klastrow (w liczebnościach 50, 100, 200) wyznaczonych przez algorytm rozmytych c -średnich, bez uwzględnienia rozmycia, czyli macierzy μ .

Do wyznaczenia metryk jakości dla tych badań, również wykorzystano algorytmy 7, 8 oraz 9. W przypadku oryginalnych danych, wejściem algorytmu 7 były etykiety wyznaczone przez algorytm `AgglomerativeClustering`. Dla środków klastrow algorytmu rozmytych c -średnich, najpierw wyznaczono przynależności punktów do tych klastrow na podstawie macierzy μ (tak samo jak dla GRAGGLO).

3.3 Wyniki

3.3.1 Czas grupowania

Algorytm GRAGGLO, który wykorzystuje wstępną granulację FCM, ma znacząco mniejszy czas wykonania w stosunku do własnej implementacji algorytmu ostrego. Charakterystykę czasu wykonania algorytmów w zależności od liczby danych przedstawiono na rys. 6.

Dla obydwu algorytmów, złożoność czasowa grupowania hierarchicznego jest sześcienna i wynosi dla algorytmu ostrego $O(X^3)$, dla rozmytego $O(G^3)$, gdzie liczba ziaren G jest stała i zdecydowanie mniejsza od liczby danych ($G \ll X$). Złożoność czasowa algorytmu rozmytych c -średnich wynosi $O(X)$, więc jest on mniej wrażliwy na zwiększanie rozmiaru danych wejściowych.




Figure 6: Charakterystyka czasu wykonania własnych implementacji algorytmów ostrego i rozmytego dla różnej liczby granul od liczby danych wejściowych.

Porównano również czas wykonania algorytmu GRAGGLO z algorytmem `AgglomerativeClustering` biblioteki `scikit-learn`, dla złożoności `SINGLELINKAGE`. Wyniki przedstawiono na rys. 7.

Wykres pokazuje, że dla małych danych (do 10 000 punktów), najkrócej wykonuje się algorytm biblioteczny – klasteryzacja algorytmem rozmytych c -średnich trwa stosunkowo długo, mimo złożoności liniowej. Powyżej 10 000 danych algorytm GRAGGLO dla 50 granul wykonywany jest szybciej niż algorytm ostry. Od 40 000 danych, jest on szybszy dla wszystkich badanych liczebności granul. Oznacza to, że mimo gorszej złożoności samego algorytmu hierarchicznego FUZZYAGGLO, całość algorytmu rozmytego jest lepsza pod względem czasu wykonania od algorytmu `AgglomerativeClustering`, powyżej pewnej liczności danych.

Czasy wykonania algorytmu rozmytego GRAGGLO na dużych danych przedstawia rys. 8. W przypadku 200 granul zauważyć można zaburzenie liniowości wyników. Spowodowane jest zbyt dużym wykorzystaniem pamięci: sama macierz μ ma wymiary $X \times G$, czyli dla 4 milionów danych wejściowych zawiera ona 800 milionów liczb zmiennoprzecinkowych. Z tego samego powodu możliwe było wykonanie algorytmu na 6 milionach danych tylko dla 50 granul – dla większej liczby nie wystarczyło pamięci.

3.3.2 Jakość grupowania

Na wykresach wyników grupowania hierarchicznego metodą rozmytą punkty szare odpowiadają współrzędnym oryginalnych danych. Wyjątkiem są wykresy danych ‘spheres’, gdzie oryginalne punkty pominięto, aby zachować czytelność wykresu. Punkty kolorowe odpowiadają środkom granul, gdzie środki o tym samym kolorze należą do tego samego klastra. Elipsy (elipsoidy dla ‘spheres’) w kolorze różowym wizualizują rozmycie granul, gdzie długość każdej półosi jest równa dwukrotności rozmycia w danym wymiarze. Mnożnik ten został wybrany ze względu na dobrą czytelność wynikowych wykresów.

Wszystkie wykresy zamieszczono w katalogu `img/granule_visualization`, pogrupowane w podkatalogach według kształtu danych (‘blobs’, ‘circles’, ‘corners’, ‘crescents’, ‘laguna’ i ‘spheres’). Nazwa każdego pliku ma format `[kształt][liczba_danych][relacja]_[łączość].pdf`, gdzie „relacja”: `t` (trójkątna), `e` (wykładnicza) lub `g` (gaussowska), a „łączość”: `s` (`SINGLELINKAGE`) lub `c` (`COMPLETELINKAGE`).

Dla niektórych wyników utworzono również wykresy na podstawie sumarycznej przynależności punktów do granul z danego klastra. Mają postać kilku podwykresów, gdzie punktami w kolorze niebieskim oznaczono dane oryginalne. Dla każdego podwykresu opisanego jako „Klaster c ”, dla każdego punktu x wyznaczana jest suma $\sum_{g=0}^G \mu_{xg} \cdot [g \in c]$, gdzie zapis $[P]$ wartościowany jest




Figure 7: Charakterystyka czasu wykonania algorytmu ostrego `AgglomerativeClustering` biblioteki `scikit-learn` i własnej implementacji algorytmu rozmytego dla różnej liczby granul od liczby danych wejściowych.




Figure 8: Charakterystyka czasu wykonania algorytmu rozmytego dla różnej liczby granul od liczby danych wejściowych dla dużych danych.

Table 2: Dokładność grupowania hierarchicznego danych algorytmem ostrym o łączności SINGLELINKAGE

kształt	dokładność			
	dane oryginalne	50 granul	100 granul	200 granul
‘blobs’	0.9899	0.9999	0.9939	0.9696
‘circles’	1.0000	1.0000	1.0000	1.0000
‘corners’	1.0000	1.0000	1.0000	1.0000
‘crescents’	1.0000	1.0000	1.0000	1.0000
‘laguna’	0.9125	0.9997	0.9998	0.9999
‘spheres’	1.0000	1.0000	1.0000	1.0000

Table 3: Trafność grupowania hierarchicznego danych algorytmem ostrym o łączności SINGLELINKAGE

kształt	trafność			
	dane oryginalne	50 granul	100 granul	200 granul
‘blobs’	0.8333	1.0000	0.9571	0.7487
‘circles’	1.0000	1.0000	1.0000	1.0000
‘corners’	1.0000	1.0000	1.0000	1.0000
‘crescents’	1.0000	1.0000	1.0000	1.0000
‘laguna’	0.7084	0.9990	0.9995	0.9997
‘spheres’	1.0000	1.0000	1.0000	1.0000

do 1, gdy warunek P jest spełniony, w przeciwnym razie do 0 (wartość μ_{xg} jest wliczana do sumy, gdy granula g należy do klastra c). Wyższe wartości tej sumy oznaczają większą przynależność punktu do tego klastra. Im wyższa wartość sumy, tym ciemniejszy kolor punktu na wykresie.

Dane syntetyczne Wyniki dokładności, trafności i precyzji otrzymane na podstawie ostrego algorytmu hierarchicznego **AgglomerativeClustering** grupującego dane oryginalne i środki klastrów wyznaczonych przez algorytm rozmytych c -średnich przedstawiają odpowiednio tabele 2, 3 i 4 dla łączności SINGLELINKAGE oraz 5, 6 i 7 dla łączności COMPLETELINKAGE.

Kształt danych Średnią dokładność grupowania danych w zależności od ich kształtu dla łączności SINGLELINKAGE i COMPLETELINKAGE przedstawiono w tabeli 8, trafność – w tabeli 9, a precyzję – w tabeli 10.

Table 4: Precyzja grupowania hierarchicznego danych algorytmem ostrym o łączności SINGLELINKAGE

kształt	precyzja			
	dane oryginalne	50 granul	100 granul	200 granul
‘blobs’	0.8295	0.9990	0.9392	0.7282
‘circles’	1.0000	1.0000	1.0000	1.0000
‘corners’	1.0000	1.0000	1.0000	1.0000
‘crescents’	1.0000	1.0000	1.0000	1.0000
‘laguna’	0.8375	0.9996	0.9998	0.9998
‘spheres’	1.0000	1.0000	1.0000	1.0000

Table 5: Dokładność grupowania hierarchicznego danych algorytmem ostrym o łączności COMPLETELINKAGE

kształt	dokładność			
	dane oryginalne	50 granul	100 granul	200 granul
‘blobs’	0.7261	0.9999	0.8956	0.7237
‘circles’	0.5620	0.5533	0.5330	0.5627
‘corners’	0.5265	0.4818	0.5053	0.5130
‘crescents’	0.7986	0.8012	0.8032	0.7822
‘laguna’	0.4508	0.4875	0.4653	0.4664
‘spheres’	0.5852	0.5712	0.5650	0.6615

Table 6: Trafność grupowania hierarchicznego danych algorytmem ostrym o łączności COMPLETELINKAGE

kształt	trafność			
	dane oryginalne	50 granul	100 granul	200 granul
‘blobs’	0.7825	1.0000	0.8822	0.9041
‘circles’	0.4900	0.4940	0.4876	0.5071
‘corners’	0.5265	0.4818	0.5053	0.5130
‘crescents’	0.7986	0.8012	0.8033	0.7822
‘laguna’	0.5447	0.6026	0.4856	0.5072
‘spheres’	0.5473	0.3729	0.4805	0.5897

Table 7: Precyzja grupowania hierarchicznego danych algorytmem ostrym o łączności COMPLETELINKAGE

kształt	precyzja			
	dane oryginalne	50 granul	100 granul	200 granul
‘blobs’	0.6054	0.9990	0.8753	0.6591
‘circles’	0.4881	0.4948	0.4880	0.5052
‘corners’	0.4956	0.4779	0.4631	0.4828
‘crescents’	0.8372	0.8072	0.8285	0.8093
‘laguna’	0.3984	0.4302	0.3561	0.3804
‘spheres’	0.5143	0.4480	0.4891	0.5324

Table 8: Dokładność grupowania hierarchicznego danych w zależności od ich kształtu i wykorzystanej łączności

kształt	dokładność	
	SINGLELINKAGE	COMPLETELINKAGE
‘blobs’	0.9874	0.8758
‘circles’	0.9982	0.5738
‘corners’	0.9485	0.5167
‘crescents’	0.9943	0.7977
‘laguna’	0.9876	0.4685
‘spheres’	0.9876	0.7056

W przypadku SINGLELINKAGE, najlepszą średnią dokładność, trafność i precyzję zaobserwowano dla danych ‘circles’. Dane ‘corners’ mają najgorszą dokładność, a dane ‘blobs’ – najgorszą trafność i precyzję.

Co istotne, dla większości plików wejściowych, za wyjątkiem niektórych danych ‘blobs’ i ‘laguna’, maksymalne wartości wszystkich metryk jakości wynosi 100%. Oznacza to, że istnieje przynajmniej jedna taka kombinacja parametrów (typu relacji, liczby granul, parametru ξ), dla których grupowanie przebiega w pełni zgodnie z oczekiwaniami.

‘blobs’ Wykresy wyników grupowania danych ‘blobs’ (rys. 9) pokazują, że wysoka dokładność uzyskana dla nich z macierzy pomyłek nie przekłada się na zgodność wyników z oczekiwaniami. Ze względu na dużą dysproporcję danych pomiędzy trzema klastrami (48 : 1 : 1), algorytm rozmytych c -średnich często traktuje dwa mniejsze z nich jako szum i nie tworzy dla nich

Table 9: Trafność grupowania hierarchicznego danych w zależności od ich kształtu i wykorzystanej łączności

kształt	trafność	
	SINGLELINKAGE	COMPLETELINKAGE
‘blobs’	0.8846	0.8968
‘circles’	0.9971	0.4970
‘corners’	0.9485	0.5167
‘crescents’	0.9943	0.7977
‘laguna’	0.9625	0.5571
‘spheres’	0.9512	0.4086

Table 10: Precyzja grupowania hierarchicznego danych w zależności od ich kształtu i wykorzystanej łączności

kształt	precyzja	
	SINGLELINKAGE	COMPLETELINKAGE
‘blobs’	0.8727	0.8325
‘circles’	0.9984	0.4947
‘corners’	0.9523	0.4840
‘crescents’	0.9964	0.8207
‘laguna’	0.9812	0.4003
‘spheres’	0.9480	0.4442

Table 11: Maksymalne wartości metryk jakości dla danych ‘blobs’ przy łączności SINGLELINKAGE.

rozmiar danych	jakość		
	dokładność	trafność	precyzja
1000	1.0000	1.0000	1.0000
2000	1.0000	1.0000	1.0000
5000	0.9998	0.9999	0.9967
10 000	1.0000	1.0000	1.0000
20 000	1.0000	1.0000	1.0000
30 000	0.9999	1.0000	0.9989
40 000	1.0000	1.0000	1.0000
50 000	0.9998	1.0000	0.9997

granul. Zawierają one jednak jedynie 4% danych, dlatego dokładność grupowania pozostaje wysoka. Trafność i precyzja lepiej odzwierciedlają zgodność z oczekiwaniami – są znacznie niższe od dokładności. Mniejsze klastry mają tę samą wagę, co większy klaster, dlatego niepoprawne grupowania wyraźnie wpływają na wartość metryki. Jako że błędy wynikają z klasteryzacji FCM, wyniki uzyskane dla grupowania samych środków granul są bardzo zbliżone do uzyskanych przy pomocy GRAGGLO.

Jak pokazuje tabela 11, dla niektórych liczebności danych nie istnieje kombinacja parametrów, dla której wartości metryk jakości wynoszą 100%. W tych przypadkach granule wyznaczane są w poprawnych miejscach, natomiast pojedyncze punkty oryginalnych danych zostają przypisane do niepoprawnej granuli. Dla tych liczebności, wartości metryk otrzymane przez algorytm ostry również nie osiągają 100%.

‘circles’ Dane ‘circles’ (rys. 10) mają najwyższe wyniki dokładności, trafności i precyzji. Dla mniejszej liczby ($G = 50$) rozmyte odległości między granulami położonymi na zewnętrznym okręgu są większe niż między okręgiem zewnętrznym a wewnętrznym, jedyne błędy grupowania pojawiają się dla tej liczebności granul, dla wysokich wartości parametru ξ ($\xi \in \{0.9, 0.95\}$). W znacznej większości przypadków, dokładność grupowania wynosi 100%, tak jak dla grupowania ostrego. Okrąg zewnętrzny jest też bardziej liczny niż wewnętrzny (proporcja 7:3). Dysproporcja ta nie jest jednak tak duża, jak w przypadku ‘blobs’, algorytm rozmytych c -średnich tworzy granule w równomiernych odstępach.

‘corners’ Klastry dla danych ‘corners’ mają nierównomierną gęstość, przez co algorytm rozmytych c -średnich tworzy więcej granul bliżej środka układu współrzędnych (rys. 11). Odległości między granulami położonymi na „ramionach” i w „środkach” klastrow są na tyle duże, że rozmyte odległości „środków” różnych klastrow mogą być od nich mniejsze. Algorytm GRAGGLO osiąga więc średnio gorsze wyniki niż algorytm ostry, choć wiele kombinacji parametrów pozwala na uzyskanie 100-procentowej dokładności. Wszystkie klastry mają tę samą liczebność, wartości dokładności, trafności i precyzji są zbliżone do siebie.

‘crescents’ Dane ‘crescents’ tworzą dwa klastry o identycznej liczebności i gęstości, dzięki czemu dokładność, trafność i precyzja ich grupowania są prawie najlepsze (rys. 12). Ze względu na bliskie położenie końców łuków, błędy wciąż mogą się pojawić – koniec jednego łuku złączony zostaje z łukiem drugim. Dzieje się tak tylko dla bardzo wysokich wartości parametru ξ – 0.9 i 0.95.

‘laguna’ Dla danych ‘laguna’ błędy mogą pojawić się, gdy pojedyncze granule utworzone zostają w większej odległości od środkowego klastra, do którego oczekiwane jest, że powinny należeć. Punkt taki może wtedy zostać zakwalifikowany, jako osobny klastr, co na rysunku 13 pokazuje przykład dla 50 granul i $\xi = 0.9$. Podobny błąd przedstawia wykres dla 200 granul i $\xi = 0.9$ – pewna grupa punktów na otaczającym okręgu jest na tyle oddalona od pozostałych, że zostaje uznana za osobny klastr, jeden ze środkowych klastrow jest łączony z pozostałą częścią okręgu.

Powyżej liczebności 20 000 punktów włącznie, dokładność nigdy nie osiąga 100% (tab. 12), jednak najczęściej wynosi powyżej 99.9%. Jak zaznaczono w sekcji dotyczącej etykietowania danych (sekcja na stronie 12), środkowe klastry są na tyle zbliżone do siebie, że na podstawie wykresu nie można definitywnie określić, które punkty pomiędzy nimi należą do którego z nich. Pojedyncze punkty mogą więc być klasyfikowane niepoprawnie z punktu widzenia przypisanych do nich etykiet.

Ilustrują to wykresy 14 oraz 15. Na rys. 14 punktów jest jedynie 1000 i wszystkie klastry są wyraźnie oddzielone od siebie. Każdy punkt wyraźnie należy do granul jednego klastra. Na rys. 15 punktów jest 40 000. Klastry środkowe (o numerach 1 i 2) pokrywają się w pobliżu współrzędnych (0, 0). Punkty w bliskim otoczeniu tych współrzędnych przynależą więc w podobnym stopniu do klastra 1 i klastra 2. Ponadto punkty położone na zewnątrz klastrow 1 i 2 są położone blisko otaczającego je okręgu, oznaczonego jako klastr 0. Można zauważyć ich wysoki stopień przynależności do tego klastra.

Table 12: Maksymalne wartości metryk jakości dla danych ‘laguna’ przy łączności SINGLELINKAGE.

rozmiar danych	jakość		
	dokładność	trafność	precyzja
1000	1.0000	1.0000	1.0000
2000	1.0000	1.0000	1.0000
5000	1.0000	1.0000	1.0000
10 000	1.0000	1.0000	1.0000
20 000	0.9999	0.9997	0.9998
30 000	0.9999	0.9998	0.9999
40 000	0.9999	0.9998	0.9998
50 000	0.9997	0.9990	0.9997

Dzięki temu nałożeniu się klastrów, jakość grupowania tych danych jest lepsza, gdy wykorzystany zostanie algorytm GRAGGLO, niż gdy zgrupowane zostaną dane oryginalne. Bez wstępnej klasteryzacji algorytmem rozmytych c -średnich, środkowe klastry są łączone ze sobą.

Proporcja danych wynosi 8:1:1 (otaczający okrąg ma większą liczebność), jednak jakość grupowania jest na tyle wysoka, że zarówno dokładność, jak i trafność i precyzja mają podobne wartości.

‘spheres’ W przypadku danych ‘spheres’ (rys. 16) można zauważyć, że wyniki poprawiają się wraz ze zwiększeniem liczby granul i zmniejszeniem wartości parametru ξ . Proporcja liczebności klastrów wynosi 9:1, trafność i precyzja są o około 4 punkty procentowe mniejsze od dokładności.

CompleteLinkage Najlepsze wyniki dla łączności COMPLETELINKAGE uzyskano dla danych ‘blobs’. Inaczej jest w przypadku najgorszych wyników: dane ‘laguna’ mają najgorszą dokładność i precyzję, a dane ‘spheres’ – najgorszą trafność. Wszystkie wyniki są znacznie gorsze od uzyskanych dla SINGLELINKAGE, za wyjątkiem trafności dla danych ‘blobs’. Jak widać na wykresach danych ‘blobs’ (rys. 17), podobnie jak dla łączności SINGLELINKAGE, jeżeli granule zostaną wyznaczone przez algorytm rozmytych c -średnich we wszystkich trzech docelowych klastrach, to grupowanie FUZZY-AGGLO przebiega poprawnie. Z kolei jeżeli granule utworzone zostaną tylko w największym z klastrów, to wyznaczone zostają w nim trzy klastry o podobnych liczebnościach. W takich przypadkach dokładność, trafność i precyzja grupowania będą niższe, niż dla SINGLELINKAGE, gdzie prawie wszystkie




Figure 9: Efekty wykonania grupowania GRAGGLO dla danych ‘blobs’ o rozmiarze 1000 i wykładniczej relacji między liczbami rozmytymi, przy łączności SINGLELINKAGE.




Figure 10: Efekty wykonania grupowania GRAGGLO dla danych ‘circles’ o rozmiarze 50 000 i euklidesowej relacji między liczbami rozmytymi, przy łączności SINGLELINKAGE.




Figure 11: Efekty wykonania grupowania GRAGGLO dla danych ‘corners’ o rozmiarze 1000 i gaussowskiej relacji między liczbami rozmytymi, przy łączności SINGLELINKAGE.




Figure 12: Efekty wykonania grupowania GRAGGLO dla danych ‘crescents’ o rozmiarze 5000 i wykładniczej relacji między liczbami rozmytymi, przy łączności SINGLELINKAGE.




Figure 13: Efekty wykonania grupowania GRAGGLO dla danych ‘laguna’ o rozmiarze 1000 i wykładniczej relacji między liczbami rozmytymi, przy łączności SINGLELINKAGE.




Figure 14: Przynależność punktów do klastrów dla danych ‘laguna’ o rozmiarze 1000.




Figure 15: Przynależność punktów do klastrów dla danych ‘laguna’ o rozmiarze 40 000.




Figure 16: Efekty wykonania grupowania hierarchicznego granul dla danych ‘spheres’ o rozmiarze 5000 i gaussowskiej relacji między liczbami rozmytymi, przy łączności SINGLELINKAGE.




Figure 17: Efekty wykonania grupowania GRAGGLO dla danych ‘blobs’ o rozmiarze 1000 i trójkątnej relacji między liczbami rozmytymi, przy łączności COMPLETELINKAGE.

granule przypisywane są do tego samego klastra.

Mimo różnic w wartościach miar jakości, wnioski dla grupowania danych ‘circles’ (rys. 18), ‘corners’ (rys. 19), ‘crescents’ (rys. 20), ‘laguna’ (rys. 21) i ‘spheres’ (rys. 22) są podobne. Algorytm COMPLETELINKAGE, jak opisano w podsekcji ??, dobrze znajduje gęste, kuliste klastry. Wymienione dane mają inne kształty, widać, że znalezione przez algorytm klastry są w przybliżeniu owalne lub elipsoidalne. Kształt danych wydaje się nie być brany pod uwagę przez algorytm.

Wyniki te należy też analizować w porównaniu z wynikami algorytmu ostrego (tabele 5, 6 i 7). Dla kształtów danych ‘blobs’ oraz ‘spheres’ nastąpiła znacząca poprawa dokładności, trafności i precyzji. Dla pozostałych danych wyniki są zbliżone do wyników algorytmu ostrego.




Figure 18: Efekty wykonania grupowania GRAGGLO dla danych ‘circles’ o rozmiarze 1000 i gaussowskiej relacji między liczbami rozmytymi, przy łączności COMPLETELINKAGE.




Figure 19: Efekty wykonania grupowania GRAGGLO dla danych ‘corners’ o rozmiarze 1000 i wykładniczej relacji między liczbami rozmytymi, przy łączności COMPLETELINKAGE.




Figure 20: Efekty wykonania grupowania GRAGGLO dla danych ‘crescents’ o rozmiarze 1000 i trójkątnej relacji między liczbami rozmytymi, przy łączności COMPLETELINKAGE.




Figure 21: Efekty wykonania grupowania GRAGGLO dla danych ‘laguna’ o rozmiarze 1000 i gaussowskiej relacji między liczbami rozmytymi, przy łączności COMPLETELINKAGE.




Figure 22: Efekty wykonania grupowania hierarchicznego granul dla danych ‘spheres’ o rozmiarze 5000 i gaussowskiej relacji między liczbami rozmytymi, przy łączności COMPLETELINKAGE.

Table 13: Dokładność grupowania hierarchicznego danych w zależności od ich kształtu i wykorzystanej łączności, gdy przynależność określana jest na podstawie relacji *-podobieństwa

kształt	dokładność			
	bez szumu		z szumem	
	SINGLELINKAGE	COMPLETELINKAGE	SINGLELINKAGE	COMPLETELINKAGE
‘blobs’	0.9900	0.8755	0.8639	0.7609
‘circles’	0.9982	0.5596	0.8136	0.4623
‘corners’	0.9488	0.5248	0.7700	0.4285
‘crescents’	0.9943	0.7869	0.8188	0.6522
‘laguna’	0.9870	0.4748	0.7995	0.3827
‘spheres’	0.9871	0.6665	0.7806	0.5485

Przynależność określona na podstawie relacji *-podobieństwa

Wyniki dla pomiarów, gdzie przynależność punktów do granul określono na podstawie relacji *-podobieństwa przedstawiono w tabelach 13, 14 i 15. Dodatkowo, gdy szum nie jest uwzględniany, dla każdego pliku wejściowego istnieje taka kombinacja parametrów, dla której wartości metryk wynoszą 100%. Dla relacji trójkątnej, tylko pewien podzbiór punktów najbliższej środków granul będzie uwzględniony, jest więc mniejsza szansa na niezgodne z oczekiwaniami przypisanie do granuli. Jak pokazuje rys. 5, wiąże się to jednak z utratą dużego odsetka informacji.

Gdy szum nie jest uwzględniany w obliczaniu metryk, ich wartości są zbliżone do metryk dla przynależności określonej na podstawie macierzy μ (tabele 8, 9 i 10), natomiast gdy jest on uwzględniony, wyniki są niższe o nawet kilkanaście punktów procentowych.

Podsumowanie Podobnie jak w przypadku algorytmu ostrego, GRAG-GLO osiąga znacznie lepsze wyniki jakości grupowania wykorzystując łączność SINGLELINKAGE niż COMPLETELINKAGE. W większości przypadków, algorytm rozmyty jest w stanie osiągnąć te same, a nawet lepsze wyniki niż algorytm ostry.

Poprawa w szczególności zachodzi w sytuacji, gdy oczekiwane klastry zaczynają się pokrywać i istnieją punkty bliskie różnym grupom, na przykład dla danych ‘laguna’ o dużych liczebnościach. Dla algorytmu ostrego, punkt taki może spowodować złączenie różnych klastrów, co pokazano na rys. ???. W przypadku algorytmu rozmytego granule są uogólnieniem grupy danych, co eliminuje takie pojedyncze punkty. Ponadto algorytm rozmytych c -średnich

Table 14: Trafność grupowania hierarchicznego danych w zależności od ich kształtu i wykorzystanej łączności, gdy przynależność określana jest na podstawie relacji *-podobieństwa

kształt	trafność			
	bez szumu		z szumem	
	SINGLELINKAGE	COMPLETELINKAGE	SINGLELINKAGE	COMPLETELINKAGE
‘blobs’	0.8585	0.8508	0.7474	0.7435
‘circles’	0.9971	0.4976	0.8125	0.4056
‘corners’	0.9485	0.5229	0.7699	0.4277
‘crescents’	0.9943	0.7868	0.8188	0.6521
‘laguna’	0.9629	0.5566	0.7769	0.4513
‘spheres’	0.9512	0.4083	0.7450	0.3251

Table 15: Precyzja grupowania hierarchicznego danych w zależności od ich kształtu i wykorzystanej łączności, gdy przynależność określana jest na podstawie relacji *-podobieństwa

kształt	precyzja			
	bez szumu		z szumem	
	SINGLELINKAGE	COMPLETELINKAGE	SINGLELINKAGE	COMPLETELINKAGE
‘blobs’	0.8525	0.8278	0.7412	0.7179
‘circles’	0.9984	0.4949	0.8138	0.4034
‘corners’	0.9524	0.4894	0.7740	0.4006
‘crescents’	0.9962	0.8105	0.8207	0.6718
‘laguna’	0.9768	0.4077	0.7920	0.3277
‘spheres’	0.9477	0.4151	0.7418	0.3411




Figure 23: Przynależność punktów do klastrów dla danych ‘blobs’ o rozmiarze 1000.

wyznacza granule bliżej środków klastrów, co dodatkowo pomaga w poprawnym grupowaniu.

Z drugiej strony, algorytm FCM może wprowadzić błędy w fazie przygotowania danych, jak pokazał przypadek danych ‘blobs’. Algorytm może błędnie wyznaczyć granule, gdy dane są bardzo niezrównoważone pod względem liczebności klastrów.

Liczba ziaren Średnią dokładność, trafność i precyzję grupowania danych w zależności od liczby granul przedstawiono odpowiednio w tabelach 16, 17 i 18. W przypadku łączności SINGLELINKAGE najlepsze wyniki osiągnęte są dla 100 granul, a dla COMPLETELINKAGE – dla 50.

Dla danych takich, jak ‘circles’ (rys. 10) czy ‘crescents’ (rys. 12), gdzie klastry mają podobną liczebność i gęstość, zwiększenie liczby granul powoduje ich zagęszczenie, przy równomiernym rozłożeniu.

Inaczej jest w przypadku danych ‘blobs’ (rys. 9). Dla większych liczebności granul, możliwe jest, że algorytm rozmytych c -średnich nie wyznaczy ani jednego środka granuli w dwóch mniejszych klastrach, przez co niemożliwe jest poprawne grupowanie. Tak samo dzieje się, gdy pogrupowane zostaną same środki granul, bez uwzględnienia rozmycia. Jak można odczytać z rys. 23, w takim przypadku większość punktów zostanie zaklasyfikowane do tego samego klastra.

Podsumowanie Choć wydawać by się mogło, że zwiększenie liczby granul, a tym samym liczby grupowanych danych, powinno poprawić jakość grupowania, wyniki klasteryzacji algorytmem GRAGGLO są lepsze, gdy liczba granul jest mniejsza – 50 lub 100. Gdy klastry mają kulisty kształt (‘blobs’, ‘laguna’), granule wyznaczane są w ich środku, a im jest ich więcej, tym

Table 16: Dokładność grupowania hierarchicznego danych w zależności od liczby granul i łączności

liczba granul	dokładność	
	SINGLELINKAGE	COMPLETELINKAGE
50	0.9792	0.6768
100	0.9872	0.6606
200	0.9853	0.6317

Table 17: Trafność grupowania hierarchicznego danych w zależności od liczby granul i łączności

liczba granul	trafność	
	SINGLELINKAGE	COMPLETELINKAGE
50	0.9639	0.6270
100	0.9700	0.6161
200	0.9352	0.5937

Table 18: Precyzja grupowania hierarchicznego danych w zależności od liczby granul i łączności

liczba granul	precyzja	
	SINGLELINKAGE	COMPLETELINKAGE
50	0.9658	0.6062
100	0.9698	0.5859
200	0.9389	0.5460

Table 19: Dokładność grupowania hierarchicznego danych w zależności od typu relacji i łączności

typ relacji	dokładność	
	SINGLELINKAGE	COMPLETELINKAGE
trójkątna	0.9952	0.6513
wykładnicza	0.9780	0.6570
gaussowska	0.9785	0.6608

Table 20: Trafność grupowania hierarchicznego danych w zależności od typu relacji i łączności

typ relacji	trafność	
	SINGLELINKAGE	COMPLETELINKAGE
trójkątna	0.9776	0.6123
wykładnicza	0.9476	0.6117
gaussowska	0.9438	0.6130

bardziej zagęszczone są w środku klastrów, co może powodować błędy obliczania przynależności danych bardziej oddalonych od tego centrum. Dodatkowo, w przypadku badanych danych, dla większej liczby granul bardziej prawdopodobne było błędne wyznaczenie granul przez algorytm FCM.

Typu liczb rozmytych Średnią dokładność grupowania danych w zależności od typu relacji między granulami dla różnych łączności przedstawiono w tabeli 19, trafność – w tabeli 20, a precyzję – w tabeli 21. Wyniki w zależności od typu relacji są zbliżone, jednak najlepszą dokładność, trafność i precyzję odnotowano dla relacji trójkątnej i łączności SINGLELINKAGE. Wiąże się to ze skończonym nośnikiem liczb rozmytych. Jako że większość kształtów danych zawiera dysproporcje w liczebności, średnie wartości trafności i precyzji są niższe od odpowiadającym im wartościom dokładności.

Wyniki dla pomiarów, gdzie przynależność punktów do granul określono na podstawie relacji *-podobieństwa przedstawiono w tabelach 22, 23 i 24. Dla relacji wykładniczej i gaussowskiej nie występuje szum, dlatego wyniki nie różnią się, gdy zostanie uwzględniony. Gdy szumu nie ma, lub nie jest uwzględniony, wartości metryk są bardzo zbliżone do metryk dla przynależności określonej na podstawie macierzy μ .

W przypadku relacji trójkątnej, szum stanowi przeciętnie około 47% da-

Table 21: Precyzja grupowania hierarchicznego danych w zależności od typu relacji i łączności

typ relacji	precyzja	
	SINGLELINKAGE	COMPLETELINKAGE
trójkątna	0.9762	0.5784
wykładnicza	0.9517	0.5790
gaussowska	0.9466	0.5807

Table 22: Dokładność grupowania hierarchicznego danych w zależności od typu relacji i łączności, gdy przynależność określana jest na podstawie relacji *-podobieństwa

typ relacji	dokładność			
	bez szumu		z szumem	
	SINGLELINKAGE	COMPLETELINKAGE	SINGLELINKAGE	COMPLETELINKAGE
trójkątna	0.9965	0.6265	0.4669	0.2999
wykładnicza	0.9779	0.6570	0.9779	0.6570
gaussowska	0.9783	0.6607	0.9783	0.6607

nych – wyniki, gdy zostaje on uwzględniony, są niemal o połowę niższe.

Podsumowanie Najwyższe wartość metryk jakości przy grupowaniu algorytmem SINGLELINKAGE uzyskuje się dla relacji trójkątnej, choć relacja wykładnicza i gaussowska również ma wysokie wyniki. Wybór typu relacji ma za to duże znaczenie, gdy na jej podstawie określa się przynależność punktów do granul – relacja trójkątna powoduje wtedy, że istotna część danych oryginalnych może nie zostać w ogóle przypisana do żadnej grupy. Dla danych, które zostały zaklasyfikowane, wartości metryk są za to wyższe, niż dla pozostałych relacji, dla których wszystkie dane są zgrupowane.

Parametr ξ Średnią dokładność, trafność i precyzję grupowania danych w zależności od parametru ξ przedstawiono na rys. 24.

Dla SINGLELINKAGE, najwyższą dokładność i precyzję – odpowiednio 99.7745% i 98.1348% – osiągnięto dla $\xi = 0.05$, najwyższą trafność – 98.3582% – dla $\xi = 0.1$. Wartości metryk spadają wraz ze wzrostem wartości parametru. Powyżej $\xi = 0.8$ następuje gwałtowne załamanie na wykresie wyników.


Zależność dokładności jest przeciwna dla COMPLETELINKAGE: najlepsze

Table 23: Trafność grupowania hierarchicznego danych w zależności od typu relacji i łączności, gdy przynależność określana jest na podstawie relacji *-podobieństwa


typ relacji	trafność			
	bez szumu		z szumem	
	SINGLELINKAGE	COMPLETELINKAGE	SINGLELINKAGE	COMPLETELINKAGE
trójkątna	0.9671	0.5907	0.4461	0.2818
wykładnicza	0.9465	0.6092	0.9465	0.6092
gaussowska	0.9426	0.6116	0.9426	0.6116

Table 24: Precyzja grupowania hierarchicznego danych w zależności od typu relacji i łączności, gdy przynależność określana jest na podstawie relacji *-podobieństwa

typ relacji	precyzja			
	bez szumu		z szumem	
	SINGLELINKAGE	COMPLETELINKAGE	SINGLELINKAGE	COMPLETELINKAGE
trójkątna	0.9659	0.5635	0.4457	0.2721
wykładnicza	0.9507	0.5789	0.9507	0.5789
gaussowska	0.9454	0.5804	0.9454	0.5804



(a) SINGLELINKAGE



(b) COMPLETELINKAGE

Figure 24: Zależność dokładności, trafności i precyzji grupowania od wartości parametru ξ .

wyniki – 67.1215% – osiągnięto dla $\xi = 0.9$. Trafność i precyzja nie wpisują się w tą zależność – ich wartości wahają się odpowiednio około 60-61% i 58%. Najwyższa wartość trafności wynosi 61.7007% dla $\xi = 0.65$, a precyzji – 58.4605% dla $\xi = 0.7$.

Podsumowanie Eksperymenty sugerują, że dla łączności SINGLELINKAGE najlepiej używać małych wartości parametru $\xi \approx 0.1$, a dla COMPLETELINKAGE – dużych $\xi \approx 0.9$.

Kombinacja parametrów Wyniki pomiarów przeanalizowano też biorąc pod uwagę złożenie wpływu różnych parametrów – kształtu, liczby granul, typu relacji, parametru ξ – przy ich uśrednieniu dla wszystkich liczebności danych oryginalnych.

W tej sekcji zamieszczono wykresy złożonych zależności dla miary dokładności. W większości przypadków, trafność i precyzja posiadają na tyle podobne zależności, że nie jest konieczne dodatkowe opisywanie ich – wnioski byłyby identyczne. Wszystkie wykresy zamieszczono w katalogu `img/complex`, pogrupowane w podkatalogach według kształtu danych ('blobs', 'circles', 'corners', 'crescents', 'laguna' i 'spheres'). Nazwa każdego pliku wskazuje na metrykę, łączność i sposób określenia przynależności danych do granul:

1. metryka: dokładność (**acc**), trafność (**rec**), precyzja (**prec**),

2. łączność: `SINGLELINKAGE (s1)`, `COMPLETELINKAGE (c1)`,
3. przynależność danych do granul: na podstawie macierzy przynależności μ (brak oznaczenia), na podstawie relacji *-podobieństwa (`shape_dep`).

‘blobs’ Jak pokazuje rys. 25, dla dokładności grupowania danych ‘blobs’ zdecydowanie największe znaczenie ma liczba granul. Najlepsze wyniki – około 100% niezależnie od innych parametrów – uzyskiwane są dla 50 granul. Dla takiej liczebności algorytm rozmytych c -średnich zazwyczaj tworzył granule we wszystkich trzech oczekiwanych klastrach.

Mniejsze znaczenie ma parametr ξ , jednak da się zauważyć spadek dokładności dla większych jego wartości dla `SINGLELINKAGE` i wzrost dokładności dla `COMPLETELINKAGE`, co jest zgodne z ogólną tendencją, przedstawioną na rys. 24. Typ relacji nie ma wyraźnego wpływu na jakość grupowania.

Jeżeli granule znalezione przez algorytm rozmytych c -średnich znajdują się we wszystkich trzech klastrach, to grupowanie `FUZZYAGGLO` przebiega poprawnie. W przeciwnym razie w centralnym klastrze, pojedyncze granule uznane zostaną za należące do innego klastra, jako że algorytm musi wyznaczyć trzy grupy (rys. 9). Parametr ξ i typ relacji mogą wtedy wpłynąć na to, ile punktów danych oryginalnych znajdzie się w tych nieprawidłowych klastrach, co prowadzi do fluktuacji dokładności.


‘circles’ Wykresy dla danych ‘circles’ (rys. 26) uwydatniają wpływ łączności na jakość grupowania.

W przypadku łączności `SINGLELINKAGE`, dokładność jest niemal zawsze równa 100%. Spada ona dla wysokich (≥ 0.9) wartości parametru ξ . Najniższe wartości są osiągane dla relacji wykładniczej, wyższe dla gaussowskiej. Dla relacji trójkątnej, wyniki pozostają na poziomie 100% nawet dla $\xi = 0.95$.


Algorytm dla łączności `COMPLETELINKAGE` nie odnajduje poprawnie klastrów, co widać na rys. 18. Badane parametry nie mają znacznego wpływu na jakość.

‘corners’ Podobnie jak w przypadku ‘circles’, grupowanie danych ‘corners’ przy łączności `COMPLETELINKAGE` nie zwraca poprawnych wyników. Rys. 27 pokazuje, że przez to pozostałe parametry nie mają zauważalnego wpływu na jakość grupowania.

Dla łączności `SINGLELINKAGE` największe znaczenie ma parametr ξ . Dokładność zmniejsza się wraz ze wzrostem wartości tego parametru. Ponadto znaczenie ma też liczba granul i typ relacji. Dokładność wcześniej zaczyna spadać dla mniejszej liczebności granul, najpierw dla relacji gaussowskiej,




(a) SINGLELINKAGE




(b) COMPLETELINKAGE

Figure 25: Zależność dokładności grupowania danych ‘blobs’ od liczby granul, typu relacji i wartości parametru ξ .



(a) SINGLELINKAGE



(b) COMPLETELINKAGE

Figure 26: Zależność dokładności grupowania danych ‘circles’ od liczby granul, typu relacji i wartości parametru ξ .

potem wykładniczej, na końcu trójkątnej. Dla relacji trójkątnej i większych liczebności granul – 100 i 200 – średnia dokładność zostaje na poziomie 100% nawet dla $\xi = 0.95$.

‘crescents’ Wnioski dla danych ‘crescents’ są bardzo podobne do wniosków dla danych ‘circles’. Jak pokazuje rys. 28, dla łączności SINGLELINKAGE średnia dokładność spada poniżej 100% dopiero dla wysokich (≥ 0.9) wartości ξ , najbardziej dla relacji wykładniczej. W przypadku COMPLETELINKAGE, również można zauważyć spadek dokładności dla tej relacji i wysokiego ξ , jednak nie ma jasnego wpływu badanych parametrów na jakość grupowania.

‘laguna’ Przy łączności SINGLELINKAGE dokładność spada wraz ze wzrostem wartości ξ – rys. 29. Najszybciej jakość zmniejsza się dla dużej liczebności granul – 200. Ma to związek z nieprawidłową przynależnością punktów do granul na zewnątrz dwóch wewnętrznych klastrów, jak widać na rys. 15. Tak jak w przypadku innych kształtów danych, najniższe wyniki są uzyskiwane dla relacji wykładniczej.


Obliczanie przynależności może też wpływać na wyniki dla COMPLETELINKAGE. Dla tej łączności znowu nie można jasno określić wpływu parametrów na dokładność grupowania, natomiast zauważyć można, że dla większych liczebności granul wyniki są bardziej zróżnicowane, natomiast dla 50 granul są one bliższe średniej.

‘spheres’ Wyniki dla danych ‘spheres’ (rys. 30) przedstawiają inne zależności od wcześniej opisanych danych.


Przy łączności SINGLELINKAGE, dokładność zmniejsza się wraz ze wzrostem parametru ξ , jednak najgorsze wyniki otrzymywane są dla najmniejszej liczebności granul – 50. Gdy jest ich mniej, granule na zewnętrznej sferze mogą być znacznie oddalone od siebie nawzajem, przez co sfera wewnętrzna łączona jest z zewnętrzną, a pojedyncza granula ze sfery zewnętrznej zostaje uznana za osobny klaster (rys. 16).

Dla COMPLETELINKAGE można zauważyć wzrost średniej dokładności grupowania wraz ze wzrostem parametru ξ , szczególnie dla 50 granul.

Podsumowanie Łączność SINGLELINKAGE jest znacznie lepszym wyborem podczas grupowania badanych danych niż COMPLETELINKAGE. Dla tej łączności, niezależnie od kształtu danych, najlepsze wyniki uzyskuje się dla niskich wartości parametru progowego ξ . Najlepiej wykorzystywać też relację trójkątną – z nielicznymi wyjątkami przy danych ‘blobs’, wyniki są najwyższe dla tego




(a) SINGLELINKAGE




(b) COMPLETELINKAGE

Figure 27: Zależność dokładności grupowania danych ‘corners’ od liczby granul, typu relacji i wartości parametru ξ .




(a) SINGLELINKAGE




(b) COMPLETELINKAGE

Figure 28: Zależność dokładności grupowania danych ‘crescents’ od liczby granul, typu relacji i wartości parametru ξ .




(a) SINGLELINKAGE




(b) COMPLETELINKAGE

Figure 29: Zależność dokładności grupowania danych ‘laguna’ od liczby granul, typu relacji i wartości parametru ξ .



(a) SINGLELINKAGE



(b) COMPLETELINKAGE

Figure 30: Zależność dokładności grupowania danych 'spheres' od liczby granul, typu relacji i wartości parametru ξ .

kształtu granul, przy zwiększaniu parametru ξ jakość najpóźniej spada dla tej relacji.

Wnioski dotyczące optymalnej liczby granul zależą od kształtu danych. Gdy klastry danych układają się w kształt kulisty – ‘blobs’, ‘laguna’ – lepsze są małe liczby granul ($G = 50$), co poprawia jakość klasteryzacji algorytmem rozmytych c -średnich. Dla pozostałych badanych kształtów lepiej wybierać większe liczby, dzięki czemu granule rozkładają się bardziej równomiernie.

Przy grupowaniu danych algorytmem o łączności COMPLETELINKAGE, w większości przypadków nie widać jasnego wpływu parametrów na wyniki, za wyjątkiem grupowania danych ‘blobs’. Dla tych danych najlepsze wyniki uzyskiwane są dla małej liczby granul ($G = 50$), wysokiej wartości ξ oraz relacji wykładniczej.

Dane ‘brightkite’ i ‘gowalla’ Ze względu na brak etykiet danych ‘brightkite’ i ‘gowalla’, jakość grupowania można ocenić wizualnie, na podstawie wykresów – odpowiednio rys. 31 i 32.


Podczas grupowania ostrego algorytmem **AgglomerativeClustering** wykorzystano losową próbkę 500 000 współrzędnych, jako że algorytm ten nie nadaje się do grupowania bardzo dużych ilości danych. Jako parametry grupowania GRAGGLO wybrano na podstawie wyników przedstawionych na stronie 22 i dalszych, relację trójkątną, 100 granul i $\xi = 0.1$. W obydwu przypadkach jako docelową liczbę klastrow wybrano 6 – jeden klaster to jeden kontynent.

Grupowanie ostre algorytmem **AgglomerativeClustering** nie odnajduje oczekiwanych klastrow. W przypadku danych ‘brightkite’, wszystkie kontynenty zostały połączone w jeden klaster, zaś elementy odstające – wyspy, ocean, błędne współrzędne – to pozostałe 5 klastrow. W przypadku danych ‘gowalla’ grupowanie jest lepsze – Ameryki stanowią osobny klaster niż reszta kontynentów – jednak wciąż 4 klastry odpowiadają wyłącznie danym odstającym.


Wyniki grupowania algorytmem GRAGGLO są dużo bliższe oczekiwaniom. Wstępna granulacja FCM pozwoliła na eliminację szumów (w tym błędnych współrzędnych), na które wrażliwy jest algorytm grupowania hierarchicznego. Zauważyć można, że duży wpływ na rozmieszczenie granul ma zagęszczenie danych – najwięcej granul powstało we współrzędnych odpowiadających Europie i Ameryce Północnej. Zarówno w przypadku danych ‘brightkite’, jak i ‘gowalla’, Europa i Azja zostały uznane za jeden klaster.

4 Podsumowanie

Do analizy danych powszechnie wykorzystuje się algorytmy grupowania. Polegają one na wyznaczeniu takich grup danych, aby wszystkie dane przyp-




(a) Grupowanie ostre próbki losowej 500 000 punktów




(b) Grupowanie algorytmem GRAGGLO całości danych

Figure 31: Wyniki grupowania hierarchicznego algorytmem ostrym `AgglomerativeClustering` i algorytmem GRAGGLO danych 'brightkite'



(a) Grupowanie ostre próbki losowej 500 000 punktów



(b) Grupowanie algorytmem GRAGGLO całości danych

Figure 32: Wyniki grupowania hierarchicznego algorytmem ostrym `AgglomerativeClustering` i algorytmem GRAGGLO danych 'gowalla'

isane do tej samej grupy były do siebie jak najbardziej podobne pod względem wybranej metryki, a dane przypisane do różnych grup – jak najbardziej niepodobne. Algorytmy takie mogą być na przykład oparte na minimalizacji pewnej funkcji kryterialnej bądź wykorzystywać zagęszczenie danych w pewnym obszarze do wyznaczenia klastrow. W pracy skupiono się na aglomeracyjnym algorytmie hierarchicznym, który polega na tworzeniu sekwencji zagnieżdżonych podziałów danych poprzez łączenie mniejszych klastrow w większe. Wadą tego algorytmu jest jego duża złożoność czasowa: sześcienna dla implementacji ogólnej. Choć istnieją specjalizowane implementacje o niższych złożonościach (kwadratowych), to pozostają one na tyle wysokie, że algorytm jest problematyczny do wykorzystania dla dużych liczebności danych.

W pracy do przyspieszenia działania aglomeracyjnego algorytmu hierarchicznego wykorzystano obliczenia granularne. Jest to dziedzina, która również stosowana jest do analizy danych. Polega na analizowaniu ich na sposób podobny do ludzkiego postrzegania rzeczywistości. Związanym z nią pojęciem jest granula informacyjna, będąca encją o pewnej semantyce. W pracy granule realizowane są przy pomocy liczb rozmytych, czyli takich liczb, które modelują pewne ostre wartości liczbowe w jakimś przybliżeniu.

W pracy zaproponowany został autorski algorytm GRAGGLO, który wykonuje grupowanie hierarchiczne na granulach informacyjnych, zamiast na oryginalnych liczbach ostrych. Krokiem przygotowawczym algorytmu jest zgrupowanie danych wejściowych (współrzędnych punktów) w granule. Wykorzystano do tego algorytm rozmytych c -średnich FCM, który ma mniejszą – liniową – złożoność czasową niż algorytm hierarchiczny. Algorytm ten grupuje dane w klastry rozmyte, czyli takie, do których każdy punkt należy w pewnym stopniu, określonym jako liczba z przedziału $[0, 1]$. Następnie klastry te przekształcane są w granule: wielowymiarowe rozszerzalne liczby rozmyte, gdzie dla każdego wymiaru wyróżnić można środek i rozmycie granuli (ziaren informacyjnych). Wykorzystano trzy kształty ziaren: trójkątne, wykładnicze i gaussowskie, definiowane przez odpowiednie rozmyte relacje *-podobieństwa. Właściwe aglomeracyjne grupowanie hierarchiczne algorytmu GRAGGLO wykorzystuje ogólną implementację o złożoności sześcienniej dostosowaną do operowania na granulach. Modyfikacje algorytmu w stosunku do standardowej, ostrej wersji, dotyczą operacji arytmetycznych i logicznych. Odległości euklidesowe między granulami również mają postać liczb rozmytych, które są następnie porównywane. Jako że wynikiem porównań liczb rozmytych jest wartość z przedziału $[0, 1]$, wprowadzony został dodatkowy parametr progowy ξ , określający, dla jakiej wartości operacja logiczna będzie ewaluowana jako prawda. Zaimplementowano dwie łączności grupowania hierarchicznego: SINGLELINKAGE oraz COMPLETELINKAGE.

W pracy przebadano własności zaproponowanego algorytmu – jego złożoność

czasową oraz jakość grupowania. Porównano czas wykonania algorytmu GRAGGLO z czasem wykonania ostrego algorytmu hierarchicznego o analogicznej implementacji dla różnych liczebności danych. Odnotowano znaczne zmniejszenie czasu wykonania – przykładowo, dla 5000 danych algorytm GRAGGLO wykonywał się 1-4 sekundy (w zależności od liczby granul), a algorytm ostry – około 100 sekund. Możliwe było też wykonanie algorytmu na bardzo dużych danych – kilku milionach punktów – w czasie rzędu kilkudziesięciu minut. Ponadto algorytm jest też szybszy od optymalnego algorytmu bibliotecznego powyżej pewnej liczby danych. Jego złożoność czasowa jest liniowa w zależności od liczby danych wejściowych – choć właściwe grupowanie hierarchiczne nadal ma złożoność sześcienną, to wykorzystuje ono granule informacyjne, których jest znacznie mniej niż danych wejściowych. Udało się więc osiągnąć główny cel pracy – znacznie zmniejszono czas wykonywania algorytmu hierarchicznego dla dużych liczebności danych. W zamian za przyspieszenie algorytmu dopuszczono pogorszenie jakości grupowania. Pomiarów dokładności, trafności i precyzji algorytmu GRAGGLO pokazały jednak, że w większości przypadków jego wyniki nie odbiegają od wyników algorytmu ostrego, a nawet mogą być lepsze. Algorytm badano dla różnych kombinacji parametrów: liczby granul, kształtu granul i parametru progowego ξ , dla obydwu zaimplementowanych łączności. Dla wszystkich parametrów, średnie wartości metryk jakości są zbliżone do wyników tych samych metryk dla algorytmu ostrego. Ponadto w większości przypadków można znaleźć taką kombinację tych parametrów, dla których wyniki są lepsze niż dla algorytmu ostrego. Analiza grupowania GRAGGLO pokazuje również, że granulacja danych wejściowych algorytmem rozmytych c -średnich pozwala na wyeliminowanie z danych elementów odstających, na które bardzo wrażliwy jest algorytm hierarchiczny.

Implementację algorytmu GRAGGLO oraz skrypty wykorzystane do badań jego działania zamieszczono w repozytorium pod adresem <https://github.com/ZofiaLor/magister-granule>.

Algorytm GRAGGLO może w prosty sposób zostać rozszerzony o inne metryki odległości. Dzięki zastosowaniu ogólnej implementacji, łatwo można też dodać inne opcje łączności, takie jak łączność średnia lub Warda. Ponadto implementację granul rozszerzyć można o inne kształty ziaren poprzez zastosowanie innych rozmytych relacji $*$ -podobieństwa.

References

Algorytm 6 Wyznaczenie przynależności punktu do granuli na podstawie relacji $\star$ -podobieństwa S

Require: $\mathbb{X}$: dane oryginalne

Require: $\mathbb{G}$: granule wyznaczone przez algorytm GRAGGLO

Require: $\mathbf{e}_g$: wektor o długości G etykiet wyznaczonych dla wszystkich granul

Require: r : typ relacji (trójkątna, wykładnicza, gaussowska)

```

1: procedure CALCULATESIMILARITYMEMBERSHIP( $\mathbb{X}, \mathbb{G}, \mathbf{e}, r$ )
2:    $\mathbf{e}_x \leftarrow \emptyset$  ▷ etykiety punktów
3:    $szum \leftarrow 0$  ▷ liczba punktów nieprzynależących do żadnej granuli
4:   for  $x$  in  $X$  do
5:      $e \leftarrow 0$ 
6:      $\mu_{max} \leftarrow 0$ 
7:     for  $i = 1$  to  $G$  do
8:        $\mu \leftarrow (\mathbb{G}[i][1] =_S x[1])$ 
9:       for  $j = 2$  to liczba wymiarów  $x$  do
10:         $\mu \leftarrow \mu \star (\mathbb{G}[i][j] =_S x[j])$  ▷  $\star$ : t-norma
11:      end for
12:      if  $\mu > \mu_{max}$  then
13:         $\mu_{max} \leftarrow \mu$ 
14:         $e \leftarrow i$ 
15:      end if
16:    end for
17:    if  $\mu_{max} > 0$  then
18:      dodaj  $i$  do  $\mathbf{e}_x$ 
19:    else ▷ punkt nie przynależy do żadnej granuli – jest szumem
20:      dodaj  $-1$  do  $\mathbf{e}_x$ 
21:       $szum \leftarrow szum + 1$ 
22:    end if
23:  end for
24:  return  $\mathbf{e}_x, szum$ 
25: end procedure

```

Algorytm 7 Wyznaczenie macierzy $\mathbf{L}$

Require: μ : macierz $X \times X$ przynależności danych do klastrów

Require: $\mathbf{e}_r$: wektor o długości X etykiet wyznaczonych dla wszystkich punktów przez algorytm ostry

Require: $\mathbf{e}_g$: wektor o długości C etykiet wyznaczonych dla wszystkich granul przez algorytm GRAGGLO

```
1: procedure CALCULATELMATRIX( $\mu, \mathbf{e}_r, \mathbf{e}_g$ )
2:    $\mathbf{L} \leftarrow$  macierz zerowa  $C \times C$ 
3:   for  $i = 1$  to  $X$  do
4:      $\mu \leftarrow \text{ARGMAX}(\mu[i])$   $\triangleright$  Indeks identyfikujący granulę, dla której
       przynależność punktu  $i$ -tego jest największa
5:     inkrementacja  $\mathbf{L}[\mathbf{e}_r[i]][\mathbf{e}_g[\mu]]$ 
6:   end for
7:   return  $\mathbf{L}$ 
8: end procedure
```

Algorytm 8 Permutacja macierzy $\mathbf{L}$

Require: $\mathbf{L}$: macierz $C \times C$, wyznaczona przez algorytm 7

```
1: procedure PERMUTELMATRIX( $\mathbf{L}$ )
2:   for  $i = 1$  to  $C - 1$  do
3:      $(w, k) \leftarrow \arg \max(\mathbf{L}[i:][i:])$   $\triangleright$  Indeksy wiersza i kolumny, w
       których znajduje się maksymalna wartość podmacierzy  $\mathbf{L}[i:][i:]$ 
4:      $w \leftarrow w + i$ 
5:      $k \leftarrow k + i$ 
6:     zamiana kolejnością wiersza  $i$ -tego i  $w$ -tego macierzy  $\mathbf{L}$ 
7:     zamiana kolejnością kolumny  $i$ -tej i  $k$ -tej macierzy  $\mathbf{L}$ 
8:   end for
9:   return  $\mathbf{L}$ 
10: end procedure
```

Algorytm 9 Wyznaczenie dokładności, trafności i precyzji

Require: $\mathbf{L}$: macierz $C \times C$, otrzymana na podstawie algorytmu 8

Require: X : liczba danych

```
1: procedure CALCULATEQUALITYMETRICS( $\mathbf{L}, X$ )
2:    $diag \leftarrow 0$  ▷ Suma wartości na przekątnej macierzy  $\mathbf{L}$ 
3:    $R \leftarrow 0$ 
4:    $P \leftarrow 0$ 
5:    $suma\_R \leftarrow$  sumy wartości dla każdego wiersza macierzy  $\mathbf{L}$ 
6:    $suma\_P \leftarrow$  sumy wartości dla każdej kolumny macierzy  $\mathbf{L}$ 
7:   for  $i = 1$  to  $C$  do
8:      $diag \leftarrow diag + \mathbf{L}[i, i]$ 
9:     if  $suma\_R[i] > 0$  then
10:       $R \leftarrow R + \mathbf{L}[i, i] / suma\_R[i]$ 
11:    end if
12:    if  $suma\_P[i] > 0$  then
13:       $P \leftarrow P + \mathbf{L}[i, i] / suma\_P[i]$ 
14:    end if
15:  end for
16:   $A \leftarrow diag / X$ 
17:   $R \leftarrow R / C$ 
18:   $P \leftarrow P / C$ 
19:  return  $A, R, P$ 
20: end procedure
```
